



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
Facultad de Ciencias

Diplomado Introducción Analítica a la Ciencia de Datos

Módulo VI: Aprendizaje no supervisado

Profesor: Salvador Zamora Muñoz

Proyecto 2

Técnicas de agrupamiento o clustering: Clusters por métodos aglomerativos y por método de K-MEANS.

Equipo 6

Integrantes	Opción de titulación
Betancourt Peralta Diego	Sí
Canul Hernández Erick Iván	Sí
Gutiérrez Gutiérrez José Omar	Sí
Hernández Pérez Maximiliano	Sí
Torres Vargas Brenda Poulette	Sí

Índice

1. Planteamiento del Problema	3
2. Clustering Jerárquico Aglomerativo	3
2.1. Metodología	3
2.1.1. Cálculo de Distancias y Exploración de Enlaces (Ligas)	3
2.1.2. Evaluación de la Tendencia al Agrupamiento (Cluster Tendency)	4
2.1.3. Optimización del Número de Clusters (Tuning de Silueta)	4
2.1.4. Validación Estructural y Visualización Avanzada	4
2.2. Interpretación y Análisis de Resultados	4
2.2.1. Evaluación de Enlaces mediante Correlación Cofenética	4
2.2.2. Diagnóstico de la Tendencia al Agrupamiento	5
2.2.3. Optimización del Número de Clústeres por Validación Cruzada	6
2.2.4. Análisis Estructural del Árbol Definitivo y Validación Externa	6
3. K-means	9
3.1. Metodología	9
3.1.1. Métodos de agrupamiento no jerárquico	9
3.1.2. Particularidades del preprocesamiento	9
3.1.3. Criterio de homogeneidad y algoritmo	9
3.1.4. Estrategia de determinación del número de grupos	10
3.1.5. Ajuste final, caracterización y validación	10
3.2. Interpretación y análisis de resultados	10
3.2.1. Remuestreo bootstrap y coeficiente de silueta	10
3.2.2. Consenso multimétodo	11
3.2.3. Partición en dos grupos	12
3.2.4. Modelo final con tres grupos	13
4. Conclusiones	16
4.1. Clustering Jerárquico Aglomerativo	16
4.2. K-means	16
4.3. Reflexión final y comparativa metodológica	17

1. Planteamiento del Problema

El proceso de postulación y admisión a programas de posgrado en instituciones internacionales representa un escenario de alta competencia, caracterizado por la evaluación simultánea de múltiples credenciales académicas y perfiles cuantitativos. Para un aspirante, enfrentarse a la toma de decisiones sobre a qué universidades aplicar suele ser un desafío complejo y subjetivo, debido a la falta de herramientas que consoliden el comportamiento histórico de los criterios de selección. En este contexto, la ciencia de datos y el aprendizaje automatizado ofrecen un enfoque analítico robusto para transformar registros históricos en conocimiento estratégico.

El presente proyecto se enfoca en el desarrollo y aplicación de técnicas de aprendizaje no supervisado utilizando el lenguaje de programación **R**. A través del análisis del conjunto de datos **Admission Predict**, el cual recopila los méritos de postulantes reales, incluyendo variables continuas duras, tales como la puntuación del examen de aptitud académica (**GRE Score**), el examen de certificación de idioma (**TOEFL Score**) y el promedio general acumulado de pregrado (**CGPA**), en combinación con evaluaciones discretas de mérito cualitativo como el prestigio de la institución de origen (**University Rating**), la solidez de la declaración de propósitos (**SOP**) y la robustez de las cartas de recomendación (**LOR**).

Este reporte implementa de forma comparativa técnicas de **Clustering Jerárquico Aglomerativo** y métodos particionales de **K-Means**. El objetivo fundamental es descubrir de manera autónoma las estructuras y agrupaciones latentes dentro de las calificaciones de los estudiantes, construyendo un sistema de segmentación que sirva como una brújula científica para orientar a futuros candidatos en la preselección de sus opciones universitarias.

2. Clustering Jerárquico Aglomerativo

2.1. Metodología

Para la estructuración del análisis de agrupamiento jerárquico aglomerativo, se implementó un flujo metodológico basado en el aprendizaje no supervisado. En primera instancia, se realizó un preprocesamiento estrictamente analítico sobre el conjunto de datos **Admission Predict**. Para garantizar la validez del aprendizaje no supervisado y evitar la contaminación de datos o *data leakage*, el preprocesamiento excluyó explícitamente la variable respuesta continua **Chance of Admit**. Asimismo, la variable dicotómica **Research** se transformó en un factor cualitativo de dos niveles (**No** y **Sí**), extrayéndose del entrenamiento matemático para preservarla únicamente como una etiqueta de control visual posterior.

Posteriormente, se extrajo la matriz de los seis predictores numéricos continuos (**GRE Score**, **TOEFL Score**, **University Rating**, **SOP**, **LOR** y **CGPA**), la cual fue normalizada mediante un escalamiento estandarizado (media $\mu = 0$ y desviación estándar $\sigma = 1$). Este paso metodológico es crucial, ya que iguala las magnitudes absolutas de las variables, previniendo que atributos con rangos mayores (como el examen GRE sobre 340 puntos) distorsionen el cálculo del espacio geométrico de las observaciones.

A partir de la matriz estandarizada, el flujo metodológico se dividió en cuatro fases analíticas:

2.1.1. Cálculo de Distancias y Exploración de Enlaces (Ligas)

La disimilitud entre los perfiles académicos de los estudiantes x_i y x_j se cuantificó a través de la métrica de **distancia Euclidiana** en un espacio de $p = 6$ dimensiones, expresada formalmente como:

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} \quad (1)$$

Donde x_{ik} es el valor escalado del predictor k para el individuo x_i . Con base en la matriz de distancias resultante, se ajustaron comparativamente cinco modelos jerárquicos explorando diferentes metodologías de enlace (*Linkage*): Promedio (**average**), Simple (**single**), Completo (**complete**), y los métodos de minimización de varianza de Ward (**Ward.D** y **Ward.D2**).

Para evaluar la fidelidad geométrica de cada árbol, se calculó la **distancia cofenética** (**cophenetic**) de cada modelo, la cual mide las distancias de fusión intra-árbol. Posteriormente, se estructuró una matriz de correlación de Pearson (**matriz_cophenetic**) para contrastar de forma directa las distancias cofenéticas contra las distancias Euclidianas reales, sirviendo como el primer filtro de selección metodológica.

2.1.2. Evaluación de la Tendencia al Agrupamiento (Cluster Tendency)

Previo a la partición definitiva, se verificó si el conjunto de datos poseía una predisposición genuina a formar grupos o si correspondía a una distribución aleatoria espacial uniforme. Para asegurar la convergencia y robustez matemática, se calculó el **Estadístico de Hopkins** mediante dos enfoques independientes: el método probabilístico de la función `get_clust_tendency` de la librería `factoextra` y la formulación robusta de la librería especializada `hopkins`.

2.1.3. Optimización del Número de Clusters (Tuning de Silueta)

Para determinar científicamente el número ideal de ramas (k) para rebanar el dendrograma, se configuró un proceso de optimización explorando una rejilla regular de $k = 2$ hasta $k = 10$ clústeres. El procedimiento se integró mediante el ecosistema moderno de `tidymodels` y `tidyclust`, utilizando un motor de estimación estadística (`stats`) y el método de enlace ganador. Para mitigar el sobreajuste, la evaluación se ejecutó bajo un esquema de **Validación Cruzada de 10 pliegues** (*10-Fold Cross-Validation*), auditando el desempeño de cada partición a través de la métrica del Coeficiente de Silueta Promedio (`silhouette_avg`).

2.1.4. Validación Estructural y Visualización Avanzada

Una vez seleccionado el número óptimo de grupos, se procedió a cortar el árbol jerárquico mediante la función `hcut`. Para diagnosticar la calidad de la asignación a nivel individual y detectar posibles observaciones mal clasificadas, se computó y graficó el perfil de siluetas de cada estudiante. Posteriormente, se exploró la flexibilidad topológica del árbol de Ward mediante el despliegue de dendrogramas estructurales avanzados de tipo rectangular (delimitado por cajas de vecindad), circular y filogénico (orientado a relaciones ramificadas). Finalmente, como parte del diseño experimental para la validación del modelo, se implementó una estrategia de Validación Externa por Contraste de Cajas (Boxplots).

2.2. Interpretación y Análisis de Resultados

2.2.1. Evaluación de Enlaces mediante Correlación Cofenética

El análisis exploratorio de las metodologías de enlace (*Linkage*) aportó la primera evidencia cuantitativa sobre la fidelidad estructural de los árboles generados. Al inspeccionar los resultados de la correlación cofenética calculada en la tabla 1, se evalúa numéricamente qué tan bien preserva cada algoritmo las distancias Euclidianas originales tras realizar las fusiones jerárquicas.

Tabla 1: Coeficientes de Correlación Cofenética por Método de Enlace.

Average	Single	Complete	Ward D	Ward D2
0.6506	0.3178	0.5822	0.6065	0.613

Al analizar detenidamente estos coeficientes, se observa el siguiente comportamiento matemático:

- El método **single** registra la correlación más baja de todo el experimento ($r = 0.3178$). Esto nos demuestra de forma cuantitativa que evaluar únicamente las distancias mínimas ignora casi toda la variabilidad de la muestra, generando un árbol que deforma por completo las distancias reales entre los alumnos.
- Por otro lado, aunque el método **average** lidera la fidelidad de las distancias con el coeficiente más alto ($r = 0.6506$), al auditar el comportamiento visual en el panel gráfico de control (2×2) de la Figura 1, se diagnosticó la presencia severa del fenómeno de encadenamiento asimétrico. Esto significa que, a pesar de su buen puntaje matemático, visualmente el enlace promedio fracasa al aglomerar de forma ineficiente a casi todos los estudiantes en una sola rama gigante amorfa, perdiendo utilidad práctica para segmentar perfiles.
- En contraste, el método **Ward.D2** ($r = 0.6130$) se consolida como la alternativa óptima para el diseño final del modelo. Registra un coeficiente robusto de 0.6130, posicionándose muy cerca del rendimiento de **average**, superando a **complete** ($r = 0.5822$) y a la versión clásica **Ward.D** ($r = 0.6065$). Esto nos confirma que la corrección de elevar al cuadrado las distancias internamente permite a **Ward.D2** lograr un balance ideal entre fidelidad matemática de preservación espacial y

una geometría simétrica, garantizando la creación de clústeres compactos, equilibrados y altamente interpretables.




Figura 1: Cuadrícula Comparativa de Dendrogramas por Métodos de Enlace.

Al realizar el análisis de corte horizontal sobre los árboles de Ward, se determinó un comportamiento geométrico homólogo sumamente robusto. Al trazar una línea de referencia en la altura crítica $h = 100$ para el método Ward.D, o en la altura $h = 20$ para el método corregido Ward.D2, el árbol se divide de forma idéntica, permitiendo **visualizar de manera contundente la existencia de 3 grandes grupos o perfiles principales de estudiantes** en la muestra antes de cualquier optimización probabilística. Esta convergencia en el número de grupos se fundamenta visualmente en el dendrograma definitivo desplegado en la Figura 2.




Figura 2: Dendrograma de Perfiles de Admisión mediante el Método Ward.D2.

2.2.2. Diagnóstico de la Tendencia al Agrupamiento

Al ejecutar la evaluación del **Estadístico de Hopkins**, las métricas cuantitativas revelaron una convergencia matemática contundente y un nivel de estructuración extraordinario en los datos. La implementación basada en la función `get_clust_tendency` computó un coeficiente de 0.997, mientras que el algoritmo robusto de la librería especializada `hopkins` ratificó un valor similar de 0.995.

Dado que ambos resultados se posicionan de manera casi perfecta en el límite superior absoluto del indicador (1.0), se rechaza de forma categórica la hipótesis nula de aleatoriedad espacial uniforme. Por lo

que podemos determinar formalmente que **"Los datos presentan una tendencia a agruparse en clústeres"**. Desde un punto de vista práctico, que estos valores estén tan cercanos a 1.0 demuestra que las calificaciones y el perfil de los alumnos no están repartidos al azar o de forma dispersa. Al contrario, nos dice que los estudiantes tienen características muy parecidas entre sí que los hacen agruparse de manera natural.

2.2.3. Optimización del Número de Clústeres por Validación Cruzada

Al evaluar los resultados del proceso de optimización promediados a lo largo de las validaciones cruzadas, el análisis cuantitativo arrojó que el punto máximo global de cohesión y separación intra-clúster se localiza en exactamente $k = 2$ clústeres, registrando el Coeficiente de Silueta Promedio más alto del experimento con un valor de 0.394. No obstante, en concordancia con el análisis visual previo de las alturas de fusión en el dendrograma de Ward ($h = 20$), las métricas demuestran que la configuración de $k = 3$ clústeres preserve un puntaje de silueta de 0.280, el cual sigue siendo saludable y aporta una mayor riqueza analítica para segmentar a los postulantes.

Este comportamiento estructural se detalla visualmente en la curva de la Figura 3. A partir de una partición de $k \geq 4$, el rendimiento de la silueta experimenta una caída drástica y lineal, desplomándose a 0.184 para cuatro grupos y llegando a un valor marginal de 0.127 para seis clústeres. Esto nos demuestra matemáticamente que intentar fragmentar la muestra en cuatro o más subgrupos es ineficiente debido a que se genera un solapamiento severo entre observaciones; las fronteras se difuminan y los perfiles de los estudiantes pierden por completo su identidad discriminatoria, validando de forma contundente la selección de estructuras de bajo orden ($k = 2$ o $k = 3$) para el diseño del modelo.




Figura 3: Evolución del Coeficiente de Silueta Promedio según el Número de Clústeres (k).

2.2.4. Análisis Estructural del Árbol Definitivo y Validación Externa

Al ejecutar el corte definitivo del árbol jerárquico bajo la configuración ganadora de `Ward.D2` y fijando un parámetro de $k = 3$ clústeres, pudimos analizar a detalle la calidad de la asignación para cada estudiante evaluando el diagnóstico individual con `fviz_silhouette`. Como se detalla explícitamente en el Cuadro 2, el algoritmo distribuyó la muestra de forma muy equilibrada, asignando 113 alumnos al Clúster 1, 156 al Clúster 2, y 131 al Clúster 3.

Tabla 2: Resumen de Estructura y Cohesión de los Clústeres Aglomerativos ($k = 3$).

Cluster	Tamaño	Ancho de Silueta Promedio
1	113	0.37
2	156	0.24
3	131	0.27

Al contrastar estos indicadores con el comportamiento visual del gráfico de la Figura 4, se observa una consistencia interna sobresaliente: el Clúster 1 registra una silueta promedio de 0.37, el Clúster 2 de 0.24 y el Clúster 3 de 0.27. La gran mayoría de las barras verticales se proyectan de forma limpia hacia arriba, confirmando coeficientes individuales positivos y un nivel mínimo de observaciones dudosas o mal asignadas en las fronteras de las ramas del árbol de Ward.

Para explorar la estructura del árbol de forma más visual, se desplegaron dendrogramas estructurales avanzados de tipo circular (Figura 5) y filogénico (Figura 6) lo que nos permite identificar la existencia de tres ramas principales bien equilibradas en tamaño que definen la segmentación de los aspirantes.




Figura 4: Coeficiente de Silueta Individual por Estudiante.




Figura 5: Visualización Estructural del Dendrograma Circular ($k = 3$).




Figura 6: Visualización Estructural del Dendrograma Filogénico Optimizado ($k = 3$).

Finalmente, aunque la probabilidad de admisión (**Chance of Admit**) se ocultó por completo durante el entrenamiento matemático de los modelos para evitar sesgos o contaminación de datos, procedimos a reinyectarla en la fase de validación externa para decodificar la identidad de estas tres ramas de forma externa y auditar el desempeño del algoritmo no supervisado.




Figura 7: Distribución de la Probabilidad de Admisión por Clúster Aglomerativo (Ward.D2).

El gráfico de diagramas de caja (*Boxplots*) resultante, desplegado en la Figura 7, demostró que las particiones calculadas a ciegas por el árbol de Ward separan de forma perfecta el éxito real de los postulantes, permitiéndonos caracterizar los clústeres de la siguiente manera:

- **Cluster 1 (Perfil de Alta Competitividad):** Consolida a un grupo de 113 estudiantes cuyas notas académicas y méritos los posicionan de forma unívoca en la zona de éxito absoluto, registrando la probabilidad media de aceptación más alta con un valor aproximado de 0.90.
- **Cluster 2 (Perfil Intermedio / Promedio):** Reúne a un volumen de 156 estudiantes con credenciales académicas sólidas y competitivas en rangos estándar, representando el grupo mayoritario de la muestra y estabilizándose alrededor de una probabilidad media de aceptación de 0.75.

- **Cluster 3 (Perfil Regular / Zona de Oportunidad):** Agrupa a los 131 aspirantes cuyas credenciales cuantitativas se ubican en los rangos más bajos de la muestra, confinándolos en el espectro de riesgo académico con una probabilidad media de aceptación de 0.60.

Al no existir solapamiento destructivo entre los cuerpos de las tres cajas en el gráfico, se comprueba visualmente que la estructura jerárquica no supervisada guarda una relación directa y perfecta con el nivel competitivo real del proceso de admisión, validando el éxito de la segmentación.

3. K-means

3.1. Metodología

3.1.1. Métodos de agrupamiento no jerárquico

El análisis de agrupamiento no jerárquico se desarrolló sobre el mismo conjunto de datos y bajo el preprocesamiento ya documentado en la sección anterior: exclusión explícita de la variable respuesta `Chance.of.Admit` para evitar la contaminación por *data leakage*, conversión de `Research` en factor cualitativo de dos niveles y estandarización de los predictores a media $\mu = 0$ y desviación estándar $\sigma = 1$.

La diferencia entre ambas familias es que los métodos aglomerativos construyen la jerarquía completa de fusiones a partir de una matriz de distancias y permiten decidir el número de grupos *a posteriori*, cortando el dendrograma a la altura que se juzgue pertinente.

Los métodos de partición, en cambio, exigen fijar el número de grupos K antes de ejecutar el algoritmo y no ofrecen ninguna representación equivalente que permita revisar esa decisión sobre la marcha. El peso metodológico se desplaza, por tanto, hacia la etapa previa de determinación de K , que constituye el núcleo de esta sección.

3.1.2. Particularidades del preprocesamiento

Respecto de la configuración empleada en el análisis aglomerativo, se introdujo una variante deliberada. Mientras que aquel operó exclusivamente sobre los seis predictores numéricos continuos, aquí se trabajó con dos matrices de entrada en paralelo:

- Una de seis variables, comparable directamente con la sección anterior.
- Otra de siete que incorpora `Research` como variable indicadora mediante `step_dummy()` dentro de una receta de `tidymodels`.

La duplicidad no es redundante sino instrumental: permite verificar si la experiencia en investigación altera la partición cuando participa del cálculo, y reservarla como etiqueta de validación externa cuando no lo hace.

3.1.3. Criterio de homogeneidad y algoritmo

El criterio optimizado es la suma de cuadrados dentro de los grupos,

$$W = \sum_{k=1}^K \sum_{i \in k} (\mathbf{x}_i - \bar{\mathbf{x}}_k)' (\mathbf{x}_i - \bar{\mathbf{x}}_k),$$

donde $\bar{\mathbf{x}}_k$ denota el centroide del grupo k . Minimizar W equivale a minimizar la traza de la matriz de suma de cuadrados intragrupal, formulación conocida como criterio de la traza y propuesta por Ward (1963); ambos criterios coinciden por ser un escalar igual a su traza.

Puesto que evaluar todas las particiones posibles resulta computacionalmente inviable salvo para muestras muy pequeñas, el algoritmo procede de forma iterativa: parte de una asignación inicial, reasigna observaciones mientras ello reduzca W , recalcula los centroides afectados y se detiene cuando ninguna reasignación produce mejora.

El procedimiento converge a un óptimo local que depende de la partición inicial, limitación que no comparte el enfoque aglomerativo. Para mitigarla se fijó `nstart = 25`, es decir, veinticinco inicializaciones

aleatorias independientes de las que se retiene la de menor varianza interna, junto con `set.seed(123)` en todas las corridas para garantizar la reproducibilidad de los resultados.

3.1.4. Estrategia de determinación del número de grupos

1. Remuestreo por Bootstrap.

Se recorrió una rejilla de $K = 1$ a 10 mediante `tune_cluster()` sobre diez muestras *bootstrap*, registrando `sse_within_total`, `sse_total` y su cociente `sse_ratio`. El remuestreo permite acompañar cada estimación de un error estándar y no solo de un valor puntual.

2. Coeficiente de silueta con validación cruzada.

Sobre la matriz de seis predictores se evaluó $K = 2$ a 10 bajo un esquema de diez pliegues, midiendo `silhouette_avg`. A diferencia del anterior, la silueta pondera simultáneamente cohesión interna y separación entre grupos, por lo que no decrece de forma mecánica con K .

3. Validación multimétodo.

Se computaron de manera complementaria el codo por suma de cuadrados, la silueta, la varianza explicada, el estadístico *GAP*, el criterio de Calinski-Harabasz mediante `cascadeKM()` y el criterio de información de Akaike.

4. Metavotación por consenso.

Finalmente se ejecutó `NbClust()` con distancia euclidiana sobre $K = 2$ a 10, procedimiento que evalúa treinta índices de validación interna y resuelve por regla de mayoría.

3.1.5. Ajuste final, caracterización y validación

Seleccionado el número de grupos, se ajustó el modelo definitivo y se extrajeron los centroides, los tamaños muestrales y las métricas de varianza (`sse_within`, `sse_ratio` y la razón SS_{entre}/SS_{total}). La caracterización de los grupos se apoyó en diagramas de caja facetados por variable estandarizada.

3.2. Interpretación y análisis de resultados

3.2.1. Remuestreo bootstrap y coeficiente de silueta

La tabla 3 reúne los dos indicadores calculados con remuestreo sobre la rejilla completa.

Tabla 3: SSE Ratio y coeficiente de silueta promedio por número de grupos.

num_clusters	sse_ratio	silhouette_avg
1	1.000	NA
2	0.532	0.396
3	0.397	0.309
4	0.356	0.252
5	0.326	0.243
6	0.298	0.186
7	0.286	0.162
8	0.275	0.168
9	0.270	0.139
10	0.263	0.107

La lectura de ambas columnas arroja conclusiones distintas: al aplicar `select_best()` sobre `sse_ratio` el procedimiento devuelve $K = 10$, resultado que conviene descartar de entrada, pues esta métrica decrece de forma casi monótona a medida que aumenta el número de grupos.

Donde esta columna sí resulta informativa es en la magnitud de ganancias sucesivas:

- El salto de $K = 1$ a $K = 2$ reduce en 0.468 puntos.
- El de $K = 2$ a $K = 3$ en otros 0.135.
- A partir de ahí las reducciones caen abruptamente a 0.039, 0.031 y 0.021.

El codo se ubica, por tanto, entre dos y tres grupos.

El coeficiente de silueta, en cambio, no tiene ese problema y permite resolver la ambigüedad: alcanza su máximo global en $K = 2$ y desciende de forma sostenida a partir de ahí.




Figura 8: Gráfica de codo del cociente W/T estimado por remuestreo bootstrap sobre diez réplicas.




Figura 9: Evolución del coeficiente de silueta promedio bajo validación cruzada de diez pliegues.

3.2.2. Consenso multimétodo

El cálculo independiente de la silueta sobre la muestra completa mediante `fviz_nbclust` reproduce el patrón anterior con notable fidelidad, lo que descarta que el resultado dependa del esquema de remuestreo empleado.

La metavotación de `NbClust` sobre treinta índices de validación interna precisa la magnitud del consenso. La tabla 4 resume la distribución de los votos.

Diez índices eligen dos grupos y ocho por tres, mientras que los cinco votos restantes se dispersan sin mostrar un patrón claro. Por mayoría, se resuelve en $K = 2$, y los valores puntuales refuerzan esa lectura: el índice de Calinski-Harabasz llega a 412.77, el de silueta 0.3942 y el de Davies-Bouldin 0.981, los tres en su mejor punto con dos grupos. Vale la pena notar, sin embargo, que la votación no es unánime sino que se divide claramente entre dos y tres grupos, y que ningún índice relevante propone más grupos que esos. Este comportamiento es el esperado cuando los datos se ordenan a lo largo de una dimensión dominante y admiten cortes válidos en más de un punto, antes que cuando existen grupos naturalmente delimitados.




Figura 10: Coeficiente de silueta calculado sobre la muestra completa (factoextra).

Tabla 4: Distribución de votos de los índices de validación interna evaluados por NbClust.

K propuesto	Índices a favor	Principales índices
2	10	Calinski-Harabasz, Silhouette, Davies-Bouldin, Duda, McClain
3	8	Hartigan, CCC, Scott, TraceW, Friedman, Ball, Dunn
4	1	TrCovW
5	1	Cindex
6	1	Marriot
9	1	KL
10	1	SDbw

3.2.3. Partición en dos grupos

Ajustado el modelo con $K = 2$, la partición distribuye la muestra en 187 y 213 estudiantes bajo la configuración de siete predictores y en 181 y 219 bajo la de seis; ambas soluciones coinciden en 394 de las 400 observaciones, de modo que incorporar **Research** al cálculo reubica apenas seis alumnos. Los centroides se presentan en el Cuadro 5.

Tabla 5: Centroides del modelo con dos grupos en unidades estandarizadas.

Cluster	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research_Sí
1 ($n = 187$)	0.776	0.744	0.770	0.753	0.714	0.802	0.829
2 ($n = 213$)	-0.682	-0.653	-0.676	-0.661	-0.626	-0.704	0.300

Las seis variables presentan centroides positivos en el primer clúster y negativos en el segundo, con magnitudes homogéneas: entre 0.714 y 0.802 en valor absoluto para el primero y entre 0.626 y 0.704 para el segundo. **Ninguna variable discrimina en dirección contraria a las demás.** Por ejemplo si los aspirantes con calificaciones altas pero cartas débiles frente al patrón inverso cabría esperar que alguna invirtiera su signo. No ocurre: la partición secciona transversalmente un único eje de competitividad académica.

Las métricas son consistentes con esa lectura. La suma de cuadrados intragrupal totaliza 1 248 unidades frente a un total de 2 493, lo que sitúa la razón SS_{entre}/SS_{total} en 50.0 % y el coeficiente de silueta del modelo ajustado en 0.387. La proyección sobre el plano de componentes principales (Figura 11) muestra dos envolventes contiguas que se tocan sobre el eje horizontal sin dejar espacio vacío entre ellas, y los diagramas de caja por variable (Figura 12) confirman el desplazamiento uniforme de las seis distribuciones.




Figura 11: Proyección de la partición con $K = 2$ sobre el plano de los dos primeros componentes principales.




Figura 12: Distribución estandarizada de cada variable académica según el clúster asignado con $K = 2$.

Aunque esta configuración logra buenos resultados en los indicadores internos, su utilidad práctica es limitada: divide la muestra solo en dos grupos, aspirantes competitivos y no competitivos, lo que aporta poco al propósito del estudio. Por eso se eligió finalmente la partición en **tres grupos**, una opción respaldada por la mayoría de los índices evaluados y que ofrece una descripción más rica de los perfiles de los aspirantes.

3.2.4. Modelo final con tres grupos

El ajuste con $K = 3$ sobre las seis variables académicas distribuye la muestra en 106, 168 y 126 estudiantes. La proyección sobre el plano de componentes principales, recogida en la Figura 13, resulta especialmente elocuente.

Partición de Perfiles Estudiantiles mediante K-Means (k = 3)




Figura 13: Proyección de la partición definitiva con $K = 3$ sobre el plano de los dos primeros componentes principales.

Las tres agrupaciones aparecen como franjas verticales consecutivas que dividen el primer componente, responsable de **75.2 %** de la variabilidad. El segundo componente, con apenas **10.3 %**, no aporta separación: los tres grupos ocupan prácticamente el mismo rango vertical.

En la práctica, la partición se apoya en una sola dirección del espacio, y las fronteras entre bandas funcionan como cortes claros pero algo arbitrarios sobre un recorrido continuo, más que como rupturas reales en los datos.

El Cuadro 6 caracteriza los grupos resultantes con la variable respuesta reincorporada tras el entrenamiento.

Tabla 6: Caracterización de los tres perfiles con la variable respuesta reincorporada.

Perfil	n	GRE	TOEFL	CGPA	% Investigación	Chance
Perfil alto	106	329.7	114.2	9.31	90.6	0.891
Perfil intermedio	168	316.9	107.8	8.61	57.1	0.721
Perfil bajo	126	305.8	101.2	7.98	21.4	0.589

La segmentación se entiende fácilmente en términos del proceso de admisión.

- El primer perfil reúne a 106 aspirantes con una puntuación GRE media de **329.7**, un promedio de pregrado de **9.31** y experiencia investigadora en el **90.6 %** de los casos, con una probabilidad media de admisión de **0.891**.
- El segundo agrupa a 168 estudiantes con perfiles intermedias y una probabilidad media de **0.721**, constituyendo el bloque mayoritario de la muestra.
- El tercero concentra a 126 aspirantes con los perfiles más bajos y una probabilidad media de **0.589**.

Ahora bien, el Cuadro 6 no introduce matices respecto al diagnóstico de dos grupos, sino que lo refuerza. Las seis variables académicas ordenan los tres perfiles en la misma secuencia, sin excepción, y lo mismo ocurre con la variable respuesta, que no participó en el cálculo.

Un conjunto con perfiles genuinamente distintos difícilmente mostraría un ordenamiento tan alineado en todas sus dimensiones de manera simultánea; lo que se observa es, nuevamente, un único gradiente, ahora dividido en tres tramos.

La Figura 14 refleja la misma jerarquía a nivel de cada variable académica: en las seis observadas las medianas aumentan de forma ordenada desde el perfil bajo al alto, sin inversiones. La única excepción aparente es **University.Rating**: sus cajas comprimidas y la abundancia de puntos marcados como atípicos no indican mayor variabilidad real, sino el efecto de ser una variable discreta de solo cinco niveles; aun así, la tendencia ordinal se mantiene igualmente clara.

La Figura 15 desglosa la variable de respuesta por perfil y ofrece una validación externa del modelo. Las medianas se ordenan con claridad en torno a **0.61**, **0.73** y **0.90**, y los cuerpos de las tres cajas no se traslapan, lo que confirma que una partición calculada sin acceso a *Chance.of.Admit* reproduce su ordenamiento.




Figura 14: Distribución estandarizada de cada variable académica según el clúster asignado con $K = 3$.




Figura 15: Distribución de la probabilidad de admisión según el perfil asignado.

La segunda vía de validación externa cruza los perfiles con *Research*, variable que no intervino en el cálculo.

La Figura 16 muestra una progresión ordenada: la experiencia investigadora está presente en el **21.4 %** de los aspirantes con perfil bajo, en el **57.1 %** del perfil intermedio y en el **90.6 %** del grupo de perfil alto. En la partición de dos grupos, esta concordancia se traduce en una tasa de acuerdo del **74.5 %**, con una discordancia de **0.255**.

El resultado admite una lectura matizada. Que la proporción crezca de forma continua confirma que la partición refleja información sustantiva del expediente.




Figura 16: Proporción de estudiantes con experiencia en investigación dentro de cada perfil.

4. Conclusiones

El proceso de admisión a posgrado enfrenta a los aspirantes a una decisión compleja y en buena medida subjetiva: a qué universidades aplicar, sin contar con las herramientas que resuman el comportamiento histórico de los criterios de selección. Con ese propósito se aplicaron dos técnicas de agrupamiento no supervisado —Clustering Jerárquico Aglomerativo y K-means— sobre el conjunto **Admission Predict**, buscando construir una segmentación que funcione como una pauta o brújula para orientar a futuros candidatos en la preselección de sus opciones universitarias.

4.1. Clustering Jerárquico Aglomerativo

El método **Ward.D2** resultó ser el más adecuado, al lograr el mejor balance entre fidelidad geométrica y claridad visual: alcanzó una correlación cofenética de $r = 0.6130$, cercana al máximo obtenido con el enlace promedio ($r = 0.6506$) pero sin el problema de encadenamiento que este último mostró al graficarse. Al cortar el árbol en su altura crítica se obtuvieron tres grupos compactos y de tamaño equilibrado (113, 156 y 131 alumnos).

El Estadístico de Hopkins, calculado por dos vías independientes ($H = 0.997$ y $H = 0.995$), descartó con claridad que esta estructura fuera producto del azar: los aspirantes sí tienden a organizarse en torno a perfiles compartidos. El Coeficiente de Silueta identificó su valor más alto en dos grupos, pero el corte en tres se mantuvo en un nivel saludable (**silhouette_avg** = 0.280) y se prefirió porque describe mejor la variedad de perfiles presentes. Al reincorporar **Chance of Admit** solo como referencia externa, los tres grupos correspondieron con claridad a distintos rangos de probabilidad de admisión: Alta Competitividad (≈ 0.90), Perfil Intermedio (≈ 0.75) y Perfil Regular (≈ 0.60).

4.2. K-means

El algoritmo particional confirmó, por su cuenta, la existencia de tres grupos diferenciados, esta vez con 106, 168 y 126 estudiantes. También aquí el mejor valor de silueta se dio con dos grupos (0.384 frente a

0.297 con tres), y también aquí se optó por trabajar con tres, porque ofrecen una lectura académica más rica y grupos mejor balanceados.

Los boxplot mostraron una jerarquía muy ordenada: el Cluster 1 concentró las medianas más altas en las seis variables académicas, con un 90.6 % de sus integrantes con experiencia en investigación; el Cluster 2 mostró justo lo contrario, con solo 21.4 %; y el Cluster 3 quedó de forma consistente en medio de ambos, con 57.1 %. Esa misma jerarquía se repitió en la probabilidad real de admisión, con medianas cercanas a 90 %, 61 % y 73 % respectivamente. Vale la pena señalar que, a diferencia de la separación limpia que se ve en las variables académicas, la probabilidad de admisión sí se traslapa de forma notoria entre grupos vecinos —el Cluster 2 baja hasta 34 % y el Cluster 3 tiene algunos casos entre 45 % y 52 %—, lo que muestra que la frontera entre perfiles es útil pero no tajante.

4.3. Reflexión final y comparativa metodológica

Trabajar con un método jerárquico y uno particional permitió, en el fondo, poner a prueba el mismo hallazgo con dos lógicas distintas: **Ward.D2** arma la partición fusionando observaciones por cercanía, sin necesidad de decidir de antemano cuántos grupos habrá; **K-means** la construye minimizando la varianza dentro de cada grupo, a partir de un número de grupos que sí hay que fijar de entrada. Que ambos hayan llegado a una solución de tres perfiles con una jerarquía académica y de probabilidad prácticamente igual es la mejor señal de que esta segmentación no depende del algoritmo que se use, sino que refleja algo real en los datos.

En conclusión, el agrupamiento no supervisado resultó útil para traducir el perfil continuo de los aspirantes en tres categorías claras y manejables: Alta Competitividad, Perfil Intermedio y Perfil Regular. Al estar respaldadas por dos algoritmos distintos y por la probabilidad real de admisión, estas categorías ofrecen una base sólida para orientar a los postulantes de posgrado en la preselección de universidades, sin perder de vista que se trata de un corte útil sobre un continuo de mérito académico, y no de tipos cerrados de estudiante.