



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO  
Facultad de Ciencias

## Diplomado Introducción Analítica a la Ciencia de Datos

Módulo VI: Aprendizaje no supervisado

Profesor: Salvador Zamora Muñoz

---

### Proyecto 1

Técnicas de reducción de dimensión: PC, t-SNE y UMAP.

---

### Equipo 6

| Integrantes                   | Opción de titulación |
|-------------------------------|----------------------|
| Betancourt Peralta Diego      | Sí                   |
| Canul Hernández Erick Iván    | Sí                   |
| Gutiérrez Gutiérrez José Omar | Sí                   |
| Hernández Pérez Maximiliano   |                      |
| Torres Vargas Brenda Poulette | Sí                   |

# Índice

|                                                                |          |
|----------------------------------------------------------------|----------|
| <b>1. Planteamiento del Problema</b>                           | <b>3</b> |
| <b>2. Estadística Descriptiva</b>                              | <b>3</b> |
| <b>3. Aplicación de las Técnicas de Reducción de Dimensión</b> | <b>4</b> |
| 3.1. Análisis de PCA . . . . .                                 | 4        |
| 3.1.1. Metodología . . . . .                                   | 4        |
| 3.1.2. Interpretación y Análisis de Resultados. . . . .        | 5        |
| 3.1.3. Conclusiones . . . . .                                  | 7        |
| 3.2. t-SNE . . . . .                                           | 7        |
| 3.2.1. Comparación de las dos implementaciones . . . . .       | 7        |

## 1. Planteamiento del Problema

Si bien durante los procesos de admisión a posgrado diversos factores académicos y personales, como el desempeño en exámenes, el promedio general de la licenciatura, la calidad de la institución de procedencia, las cartas de recomendación, la declaración de propósitos y la experiencia en investigación, impactan en la probabilidad de que un aspirante sea admitido, dichos factores pueden presentar distintos niveles de correlación y redundancia, de modo que resulta pertinente analizar su estructura mediante técnicas de reducción de dimensión para identificar las variables que aportan mayor información, simplificar el espacio de características y facilitar la interpretación de los datos sin perder una cantidad significativa de información.

En este sentido, analizamos el conjunto de datos de **Admission Predict**, integrado por 400 observaciones correspondientes a solicitudes de admisión y 8 variables, de las cuales 7 corresponden a variables predictoras y una a la variable respuesta. A continuación, se presenta una breve descripción de las mismas:

- **GRE Score:** puntuación obtenida en el examen GRE (0–340).
- **TOEFL Score:** puntuación obtenida en el examen TOEFL (0–120).
- **University Rating:** calificación de la universidad de procedencia (escala de 1 a 5).
- **SOP:** evaluación de la declaración de propósito (Statement of Purpose), en una escala de 1 a 5.
- **LOR:** evaluación de las cartas de recomendación (Letter of Recommendation), en una escala de 1 a 5.
- **CGPA:** promedio general de licenciatura, expresado en una escala de 0 a 10.
- **Research:** variable binaria que representa si el aspirante cuenta (1) o no (0) con experiencia en investigación.
- **Chance of Admit:** Variable continua acotada en el intervalo  $[0, 1]$ , que representa la probabilidad estimada de

## 2. Estadística Descriptiva

En la figura 1 observamos una relación positiva entre la variable Chance of Admit y el resto de variables continuas (GRE Score, TOEFL Score y CGPA), por lo que los alumnos con mejores calificaciones en el examen GRE, TOEFL y mejor GPA tienen más probabilidad de ser admitidos en el programa de maestría de su elección.




Figura 1: Relación entre las variables continuas y Chance of Admit

En la figura 2 se tiene un boxplot de Chance of Admit por cada categoría de cada una de las variables categóricas (University Rating, SOP, LOR y Research).




Figura 2: Boxplots de Chance of Admit por cada categoría de las variables categóricas

En la figura 3 observamos en la matriz de correlación de Pearson que todas las variables están correlacionadas entre sí de manera positiva. Todas las correlaciones son de al menos 0.4, por lo que hay una estructura de asociación lineal fuerte entre las variables.

Así mismo, la matriz de correlación tiene un determinante de 0.0033, lo cual confirma todavía más la fuerte correlación entre las variables.

La medida de adecuación muestral (MSA por sus siglas en inglés) de Kaiser, Meyer, Olkin (KMO) es un valor que va de 0 a 1 y que es útil para medir qué tan adecuado es realizar un análisis de componentes principales con los datos de interés. Valores mayores indican que es conveniente realizar un análisis de este tipo con los datos. El valor obtenido con estos datos fue de 0.903, por lo que realizar un análisis de componentes principales es apropiado.

### 3. Aplicación de las Técnicas de Reducción de Dimensión

#### 3.1. Análisis de PCA

##### 3.1.1. Metodología

El análisis de componentes principales se aplicó sobre el conjunto de variables predictoras estandarizadas mediante el procedimiento de normalización, integrando tanto las variables cuantitativas: **GRE Score**, **TOEFL Score**, **University Rating**, **SOP**, **LOR** y **CGPA**, como la variable categórica **Research**, la cual fue convertida a tipo factor con dos niveles (No y Sí). No obstante, **Chance of Admit** se excluyó del cálculo, asignándole el rol de *outcome* y se conservó únicamente para facilitar la interpretación posterior de los resultados.

Así pues, una vez extraídos los componentes principales, se obtuvo su matriz de cargas factoriales, que se muestra en la tabla 1, las cuales indican la contribución de cada variable original a la construcción




Figura 3: Matriz de correlación

de cada componente, así como su matriz de varianza explicada asociada a cada uno y la acumulada en términos porcentuales, la cual se muestra en la tabla 2.

Tabla 1: Matriz de cargas factoriales absolutas de los componentes principales

| Variable          | PC1    | PC2     | PC3     | PC4     | PC5     | PC6     | PC7     |
|-------------------|--------|---------|---------|---------|---------|---------|---------|
| CGPA              | 0.4174 | -0.0206 | -0.2452 | 0.1407  | -0.0358 | -0.5876 | 0.6316  |
| GRE Score         | 0.3982 | -0.2874 | -0.3553 | 0.2039  | -0.0592 | -0.2752 | -0.7154 |
| LOR               | 0.356  | 0.4495  | 0.4134  | 0.5922  | -0.344  | 0.1681  | -0.0552 |
| Research Yes      | 0.2915 | -0.7239 | 0.6084  | -0.0666 | -0.0079 | 0.0747  | 0.1038  |
| SOP               | 0.3822 | 0.3505  | 0.2569  | -0.2143 | 0.7676  | -0.0989 | -0.1421 |
| TOEFL Score       | 0.3989 | -0.1231 | -0.4545 | 0.0828  | 0.1687  | 0.7299  | 0.2261  |
| University Rating | 0.3877 | 0.2301  | 0.0064  | -0.7285 | -0.509  | 0.0513  | -0.065  |

Tabla 2: Varianza explicada y acumulada por los componentes principales

| PC | Varianza explicada (%) | Acumulada (%) |
|----|------------------------|---------------|
| 1  | 69.61                  | 69.61         |
| 2  | 10.36                  | 79.97         |
| 3  | 7.81                   | 87.78         |
| 4  | 4.43                   | 92.21         |
| 5  | 3.50                   | 95.71         |
| 6  | 2.27                   | 97.98         |
| 7  | 2.02                   | 100.00        |

### 3.1.2. Interpretación y Análisis de Resultados.

Notemos que el primer componente principal (**PC1**) **concentra 69.61%** de la variabilidad total del conjunto de datos, lo que indica que una gran parte de la información contenida en las siete variables predictoras puede resumirse en una única dimensión latente. Por otra parte, al incorporar el

segundo componente principal (**PC2**), la **varianza acumulada asciende a 79.97 %**, lo que representa aproximadamente el 80 % de la variabilidad total. Asimismo, con la inclusión del tercer componente principal (**PC3**) **se alcanza una varianza acumulada de 87.78 %**, mientras que los componentes restantes aportan incrementos relativamente pequeños, inferiores al 5 % de manera individual.

De modo que los resultados muestran que la mayor parte de la información del conjunto de datos se encuentra concentrada en los primeros componentes principales, lo que confirma la existencia de correlación entre las variables originales. Ahora bien, considerando el criterio de conservar alrededor del 80 % de la varianza explicada, se concluye que **dos componentes principales son suficientes para representar adecuadamente la estructura de los datos**, permitiendo reducir el número de dimensiones de siete a dos con una pérdida mínima de información.

En cuanto a las cargas factoriales, observamos que el PC1 presenta cargas de magnitud similar para todas las variables predictoras, siendo ligeramente mayor para **CGPA** (0.417), seguida de **TOEFL Score** (0.399), **GRE Score** (0.398) y **University Rating** (0.388), lo que sugiere que el primer componente resume un factor asociado al desempeño académico general de los postulantes, mientras que en el PC2 domina la variable **Research** con una carga absoluta de 0.724, superando ampliamente a la del resto de las variables, indicando que el segundo componente captura principalmente la variabilidad asociada a la experiencia en investigación, mientras que variables como **LOR** (0.449), **GRE Score** (0.287) y **University Rating** (0.230) presentan una contribución moderada.

Ahora bien, al proyectar a los postulantes sobre el plano definido por PC1 y PC2 (figura 4), coloreando cada punto según su **Chance of Admit**, se observa un gradiente claro a lo largo del eje PC1: los estudiantes con mayor probabilidad de admisión se concentran en la región de valores negativos de PC1, mientras que aquellos con menor probabilidad se agrupan principalmente en la región de valores positivos.

#### Graduates Admission: Gradiente de Probabilidad de Admisión Varianza explicada por dos componentes: 79.97 %




Figura 4: Proyección de los postulantes sobre PC1 y PC2, coloreada según la probabilidad de admisión

Este patrón resulta consistente con la interpretación anterior de PC1 como un factor asociado al desempeño académico general, y resulta particularmente relevante dado que **Chance of Admit** no participó en el cálculo de los componentes, lo cual sugiere que la estructura de correlación capturada de forma no supervisada por el PCA coincide, en buena medida, con el resultado que en la práctica resulta más relevante para el proceso de admisión.

De manera complementaria, al segmentar a los postulantes según su experiencia en investigación (figura 5) se observa una separación clara a lo largo del eje PC2: los estudiantes con experiencia en investigación (**S1**) se concentran principalmente en la región de valores positivos de PC2, mientras que aquellos sin

experiencia (No) se ubican mayoritariamente en la región de valores negativos, sin que se aprecie una separación equivalente a lo largo de PC1.

### Graduates Admission: Separación por Experiencia en Investigación Varianza explicada por dos componentes: 79.97 %




Figura 5: Proyección de los postulantes sobre PC1 y PC2, segmentada según experiencia en investigación

#### 3.1.3. Conclusiones

Así pues, es posible concluir que la variabilidad original contenida en las siete variables predictoras puede resumirse de manera adecuada en dos dimensiones interpretables: **una asociada al desempeño académico y otra a la experiencia en investigación**, las cuales en conjunto **retienen el 79.97 % de la información total**.

## 3.2. t-SNE

A diferencia de PCA, que construye combinaciones lineales de las variables originales, t-SNE modela la similitud entre pares de observaciones mediante una distribución gaussiana en el espacio de alta dimensión y una distribución t-Student, minimizando la divergencia de Kullback-Leibler entre ambas por descenso de gradiente. La matriz sometida a t-SNE se construyó seleccionando las variables cuantitativas, excluyendo **Chance of Admit** por su condición de variable respuesta. Se empleó el mismo conjunto de predictores estandarizados utilizado en el análisis de componentes principales.

### 3.2.1. Comparación de las dos implementaciones

Se emplearon dos implementaciones disponibles: `tsne()` (algoritmo exacto) y `Rtsne()` (aproximación de Barnes-Hut con `theta = 0.5`), que reduce la complejidad y acelera el cálculo —aproximadamente veinte veces—. Aunque ambas producen configuraciones cualitativamente equivalentes, la mayor rapidez de `Rtsne()` fue determinante para la exploración sistemática de hiperparámetros; `tsne()` se reservó únicamente para la verificación inicial del comportamiento del algoritmo.

En la figura 6 las observaciones se concentran en un núcleo denso alrededor del origen, mientras que unas cuantas están dispersas a gran distancia. El *embedding* queda así dominado por unas pocas observaciones que la optimización expulsó a distancias lejanas, y el resto de la estructura se vuelve ilegible por compresión de escala.




Figura 6: Salida de `tsne()` con parámetros por defecto, coloreada según `Chance of Admit`